TRƯỜNG ĐẠI HỌC HÙNG VƯƠNG TP. HỒ CHÍ MINH — KHOA KỸ THUẬT CÔNG NGHỆ

Học phần: Lập trình cho Trí tuệ nhân tạo và Khoa học dữ liệu (Mã HP: 04224)

HƯỚNG DẪN THỰC HIỆN ĐỒ ÁN CUỐI KỲ

Hình thức: Báo cáo nhóm (3–5 sinh viên) · Học kỳ I, năm học 2026–2027

PHẦN A — HƯỚNG DẪN CHUNG

1. Mục tiêu đồ án

Đồ án cuối kỳ giúp sinh viên vận dụng trọn vẹn quy trình khoa học dữ liệu đã học trong Tuần 1–10: từ làm sạch dữ liệu, trực quan hóa, xây dựng và đánh giá mô hình học máy, đến trình bày kết quả. Đồ án đánh giá các chuẩn đầu ra CLO1–CLO5 của học phần.

2. Tổ chức nhóm và chọn đề tài

- Mỗi nhóm gồm 3–5 sinh viên và chọn 01 đề tài trong 15 đề tài ở Phần B.
- Đăng ký đề tài với giảng viên trong tuần quy định; nêu rõ nguồn dữ liệu dự kiến và ít nhất 03 mục tiêu / câu hỏi phân tích cụ thể để giảng viên xác nhận trước khi triển khai.
- Mỗi đề tài nên do không quá 1–2 nhóm thực hiện (theo sắp xếp của giảng viên).
- Phân công rõ vai trò từng thành viên; mọi thành viên phải hiểu và giải thích được toàn bộ bài làm khi vấn đáp.

3. Quy trình thực hiện

Bám theo quy trình xây dựng mô hình đã học trên lớp:

Bước 1 — Xác định bài toán: dự đoán hay mô tả; biến mục tiêu (nhãn); tiêu chí thành công; một đường cơ sở (baseline) để so sánh.

Bước 2 — Thu thập và tìm hiểu dữ liệu: nguồn hợp pháp, kiểm chứng được; báo cáo số dòng, số cột, kiểu dữ liệu, tỷ lệ thiếu theo cột.

Bước 3 — Làm sạch dữ liệu: xử lý giá trị thiếu, sai kiểu, trùng lặp, ngoại lai; ghi lại từng quyết định cùng lý do.

Bước 4 — Khám phá và trực quan hóa (EDA): ít nhất 05 biểu đồ có nhãn đầy đủ, mỗi biểu đồ kèm một nhận định.

Bước 5 — Chuẩn bị đặc trưng: mã hóa, chuẩn hóa; đặt trong Pipeline / ColumnTransformer; fit trên tập huấn luyện, transform trên mọi tập để tránh rò rỉ dữ liệu.

Bước 6 — Huấn luyện mô hình: chia train/test đúng cách; huấn luyện ít nhất 02 mô hình và so sánh với baseline.

Bước 7 — Đánh giá: chọn độ đo phù hợp bài toán; ma trận nhầm lẫn hoặc RMSE / MAE / R^2; kiểm định chéo; tinh chỉnh siêu tham số bên trong pipeline.

Bước 8 — Phân tích lỗi và giới hạn: xem các mẫu bị dự đoán sai; nêu hạn chế và hướng cải tiến.

Bước 9 — (Tùy chọn) Triển khai demo: Streamlit hoặc FastAPI; lưu cả pipeline bằng joblib.

Bước 10 — Viết báo cáo và chuẩn bị trình bày, demo, vấn đáp.

4. Sản phẩm nộp

- Báo cáo (PDF hoặc DOCX) theo cấu trúc gợi ý ở mục 7.
- Mã nguồn: notebook (.ipynb) hoặc module Python, chạy được từ đầu đến cuối.
- Tệp requirements.txt và README.md (hướng dẫn chạy).
- Mô hình đã lưu (nếu có demo); dữ liệu hoặc liên kết tới dữ liệu.
- Slide trình bày và (khuyến khích) liên kết tới bản demo.
- Nộp dưới dạng kho mã nguồn (Git) hoặc tệp nén; phải chạy được trên môi trường sạch.

5. Yêu cầu kỹ thuật bắt buộc

- Luôn có baseline để so sánh — không có baseline thì con số độ chính xác không mang nhiều ý nghĩa.
- Không rò rỉ dữ liệu (data leakage): mọi tiền xử lý nằm trong pipeline và chỉ fit trên tập huấn luyện.
- Tái lập được: cố định seed ngẫu nhiên; ghi lại phiên bản thư viện.
- Chọn độ đo là một quyết định nghiệp vụ, phải giải thích vì sao chọn độ đo đó.

6. Liêm chính học thuật và sử dụng công cụ AI

- Được dùng trợ lý AI để giải thích lỗi, tra cứu API, gợi ý hướng tiếp cận — nhưng phải ghi rõ tên công cụ và cách đã dùng.
- Không nộp bài mà mã nguồn hoặc phần phân tích do AI sinh ra toàn bộ; mỗi thành viên phải giải thích và chỉnh sửa được mã của nhóm tại buổi vấn đáp.
- Dữ liệu phải hợp pháp, tôn trọng quyền riêng tư và ghi rõ nguồn.

7. Cấu trúc báo cáo gợi ý

(1) Trang bìa (tên đề tài, nhóm, danh sách thành viên, lớp). (2) Giới thiệu bài toán và mục tiêu. (3) Dữ liệu và làm sạch. (4) Khám phá và trực quan hóa. (5) Phương pháp (đặc trưng, mô hình, cách đánh giá). (6) Kết quả và so sánh với baseline. (7) Phân tích lỗi và giới hạn. (8) (Tùy chọn) Triển khai. (9) Kết luận. (10) Phân công công việc và tài liệu tham khảo; phụ lục.

8. Tiêu chí chấm điểm (10 điểm)

Phần	Nội dung đánh giá	Điểm
Câu 1 (4,0đ)	Dữ liệu, khám phá và chuẩn bị: xác định bài toán và baseline; làm sạch dữ liệu; EDA ≥ 5 biểu đồ có nhận định; chuẩn bị đặc trưng không rò rỉ; báo cáo – mã nguồn tái lập được.	4,0
Câu 2 (4,0đ)	Mô hình hóa và đánh giá: chia dữ liệu đúng cách; ≥ 2 mô hình so với baseline; chọn độ đo phù hợp, ma trận nhầm lẫn hoặc RMSE/MAE/R^2; kiểm định chéo và tinh chỉnh; phân tích lỗi; (tùy chọn) demo.	4,0
Câu 3 (2,0đ)	Trình bày, demo và vấn đáp: demo trực tiếp; mỗi thành viên bảo vệ và giải thích phần đóng góp của mình.	2,0
Tổng		**10,0**

Chi tiết thang điểm xem Đáp án (BM06). Việc chọn và giải thích độ đo được chấm ngang với phần viết mã.

9. Mốc thời gian gợi ý

Giai đoạn	Công việc chính
Đăng ký đề tài	Chọn đề tài; xác định bài toán, nguồn dữ liệu và baseline; đăng ký với giảng viên.
Giữa chặng	Hoàn thành làm sạch dữ liệu và khám phá / trực quan hóa (EDA).
Trước khi nộp	Hoàn thành huấn luyện, đánh giá và phân tích lỗi; (tùy chọn) dựng demo.
Nộp và bảo vệ	Nộp báo cáo và mã nguồn; trình bày, demo và vấn đáp.

Thời điểm cụ thể của từng mốc theo lịch của giảng viên phụ trách.

PHẦN B — CÂU HỎI ĐỊNH HƯỚNG CHO TỪNG ĐỀ TÀI

Với đề tài đã chọn, nhóm cần trả lời được các câu hỏi định hướng tương ứng trong báo cáo và khi vấn đáp. Ngoài ra, mọi đề tài đều phải trả lời bộ câu hỏi chung dưới đây.

Bộ câu hỏi chung (áp dụng cho mọi đề tài)

- Đây là bài toán gì (phân lớp, hồi quy hay phân cụm)? Biến mục tiêu là gì?
- Tiêu chí thành công và đường cơ sở (baseline) của nhóm là gì?
- Dữ liệu lấy từ đâu, có hợp pháp và kiểm chứng được không? Bao nhiêu mẫu / đặc trưng, tỷ lệ thiếu ra sao?
- Nhóm đã gặp và xử lý những vấn đề làm sạch dữ liệu nào?
- Đã phòng tránh rò rỉ dữ liệu (data leakage) bằng cách nào?
- Chọn độ đo nào và vì sao phù hợp với bài toán?
- So với baseline, mô hình tốt hơn ở điểm nào? Những mẫu bị dự đoán sai điển hình là gì?
- Giới hạn của giải pháp và hướng cải tiến?

Đề tài 1 — Dự đoán khách hàng rời dịch vụ viễn thông (Telco Customer Churn)

- Biến mục tiêu "rời mạng / ở lại" có mất cân bằng không? Điều đó ảnh hưởng thế nào tới việc chọn độ đo (accuracy so với precision / recall / F1)?
- Nhóm ưu tiên "bắt đúng khách sắp rời" (recall) hay "không làm phiền khách trung thành" (precision)? Vì sao?
- Những đặc trưng nào (thời hạn hợp đồng, cước phí, dịch vụ kèm theo) có vẻ quan trọng? Kiểm chứng bằng gì?
- Doanh nghiệp dùng dự đoán này để làm gì (chiến dịch giữ chân)? Nên đặt ngưỡng quyết định thế nào?
- Có rủi ro rò rỉ dữ liệu nào không (ví dụ đặc trưng chỉ xuất hiện sau khi khách đã rời)?

Đề tài 2 — Dự đoán khả năng sống sót của hành khách trên tàu Titanic

- Biến mục tiêu là gì? Những đặc trưng nào (giới tính, hạng vé, tuổi) liên quan tới khả năng sống sót?
- Cột nào thiếu nhiều (Age, Cabin) và nhóm xử lý ra sao, vì sao chọn cách đó?
- Nhóm tạo đặc trưng mới nào (ví dụ gộp danh xưng, kích thước gia đình)?

- Baseline hợp lý ở đây là gì (ví dụ "nữ thì sống")? Mô hình có vượt baseline không?
- Mô hình có giải thích được không (cây quyết định)? Ba luật quyết định đầu tiên nói lên điều gì?

Đề tài 3 — Dự đoán nguy cơ mắc bệnh tiểu đường (Pima Indians Diabetes)

- Giá trị 0 ở các cột (Glucose, BloodPressure, BMI) là giá trị thật hay dữ liệu thiếu trá hình? Nhóm xử lý thế nào?
- Trong y tế, bỏ sót ca bệnh (FN) và báo động nhầm (FP) có chi phí khác nhau — nhóm ưu tiên recall hay precision?
- Dữ liệu có mất cân bằng không? Ngoài accuracy, nhóm dùng độ đo nào?
- Nhóm diễn giải đặc trưng quan trọng thế nào mà không suy ra quan hệ nhân quả sai?
- Nên chọn ngưỡng phân loại theo mục tiêu sàng lọc bệnh như thế nào?

Đề tài 4 — Phân loại chất lượng rượu vang (UCI Wine Quality)

- Đây là bài toán hồi quy (điểm chất lượng) hay phân lớp (tốt / không tốt)? Nhóm chọn cách nào, vì sao?
- Dữ liệu rượu đỏ và rượu trắng có gộp chung không? Việc gộp ảnh hưởng gì tới kết quả?
- Các mức chất lượng có mất cân bằng (rất ít mẫu điểm cao/thấp) không? Ảnh hưởng tới đánh giá ra sao?
- Đặc trưng lý–hóa nào ảnh hưởng mạnh tới chất lượng? Kiểm chứng bằng cách nào?
- Mô hình nhóm chọn có cần chuẩn hóa đặc trưng không?

Đề tài 5 — Dự đoán giá nhà (Ames / California Housing)

- Đây là bài toán hồi quy; nhóm dùng độ đo nào (RMSE / MAE / R^2) và ý nghĩa thực tế của nó (sai số bao nhiêu)?
- Biến mục tiêu (giá) có lệch phân phối không? Có nên biến đổi (ví dụ log) không?
- Đặc trưng phân loại (khu vực, loại nhà) được mã hóa bằng cách nào?
- Có giá trị ngoại lai bất thường không? Nhóm xử lý thế nào?
- Mô hình tuyến tính và mô hình cây / boosting khác nhau ra sao trên dữ liệu này?

Đề tài 6 — Dự đoán giá xe ô tô đã qua sử dụng

- Dữ liệu giá xe lấy từ nguồn nào, có đáng tin và kiểm chứng được không?
- Các đặc trưng (năm sản xuất, số km đã đi, hãng, hộp số) cần làm sạch và mã hóa thế nào?
- Giá xe có lệch phân phối mạnh không? Có cần biến đổi không?
- Làm sao tránh rò rỉ khi có đặc trưng tương quan rất cao với giá?
- Mức sai số dự đoán nào thì chấp nhận được trong thực tế?

Đề tài 7 — Dự đoán tiêu thụ điện của thiết bị gia dụng (UCI Appliances Energy)

- Đây là dữ liệu theo thời gian — nhóm chia train/test theo thời gian hay ngẫu nhiên? Vì sao điều này quan trọng?
- Nhóm tạo các đặc trưng thời gian nào (giờ, thứ, mùa)?
- Có tự tương quan theo thời gian không? Baseline "dự đoán bằng giá trị kỳ trước" cho kết quả ra sao?
- Độ đo RMSE / MAE nói lên điều gì về sai số tiêu thụ điện?
- Đặc trưng môi trường (nhiệt độ, độ ẩm) nào ảnh hưởng mạnh nhất?

Đề tài 8 — Dự đoán nhu cầu thuê xe đạp công cộng (UCI Bike Sharing)

- Đây là hồi quy theo thời gian / thời tiết — nhóm chia dữ liệu thế nào cho trung thực?
- Các đặc trưng mùa, ngày lễ, giờ cao điểm được tạo và sử dụng ra sao?
- Baseline hợp lý (ví dụ trung bình theo giờ) là gì? Mô hình vượt bao nhiêu?
- Thời tiết (nhiệt độ, mưa) ảnh hưởng tới nhu cầu thế nào — trực quan hóa ra sao?
- Kết quả dự đoán dùng để làm gì (điều phối xe)?

Đề tài 9 — Phân loại tin nhắn / email rác bằng TF-IDF (SMS Spam Collection)

- Văn bản được biểu diễn thế nào (bag-of-words / TF-IDF)? Vì sao TF-IDF + mô hình tuyến tính là baseline bắt buộc phải vượt qua?
- Dữ liệu mất cân bằng (ít spam) ảnh hưởng gì tới độ đo? Dùng precision / recall ra sao?
- Nhóm đã tiền xử lý văn bản thế nào (chuẩn hóa chữ, loại ký tự, token hóa)?
- Chi phí của FP (chặn nhầm tin thật) so với FN (bỏ sót spam) khác nhau thế nào?
- Những từ / đặc trưng nào mang tính "spam" nhất?

Đề tài 10 — Phân tích cảm xúc bình luận, đánh giá sản phẩm

- Dữ liệu bình luận / đánh giá lấy từ đâu; nhãn cảm xúc có sẵn hay nhóm phải tự gán?
- Văn bản được biểu diễn bằng gì? Baseline TF-IDF + Logistic Regression cho kết quả ra sao?
- Nếu dùng tiếng Việt, việc tách từ và xử lý dấu có gì khác?
- Những mẫu nào mô hình hay nhầm (câu mỉa mai, câu phủ định)?
- Nếu các lớp cảm xúc mất cân bằng thì dùng độ đo nào?

Đề tài 11 — Phân khúc khách hàng bằng K-means và PCA

- Đây là học không giám sát, "không có một đáp án đúng" — nhóm đánh giá chất lượng cụm bằng gì (elbow, silhouette)?
- Vì sao bắt buộc chuẩn hóa đặc trưng trước khi chạy K-means?
- Chọn số cụm k bằng cách nào, và diễn giải mỗi cụm thành một "chân dung khách hàng" ra sao?
- Dùng PCA để làm gì (nhìn cấu trúc 2D)? Giữ lại bao nhiêu phần trăm phương sai?
- Kết quả phân khúc giúp ích gì cho hoạt động kinh doanh?

Đề tài 12 — Dự đoán kết quả học tập của sinh viên (UCI Student Performance)

- Bài toán là dự đoán điểm (hồi quy) hay đỗ / trượt (phân lớp)? Nhóm chọn gì, vì sao?
- Có rủi ro đạo đức / định kiến khi dùng các đặc trưng nhạy cảm (giới tính, hoàn cảnh gia đình) không?
- Đặc trưng nào dự báo kết quả mạnh nhất? Có nên dùng để can thiệp sớm?
- Baseline và độ đo nào phù hợp?
- Có rò rỉ dữ liệu không (ví dụ dùng điểm gần cuối để dự đoán điểm cuối)?

Đề tài 13 — Phân loại chữ số viết tay (MNIST / Digits)

- Ảnh được biểu diễn thế nào (vector pixel, kích thước shape)? Vì sao cần chuẩn hóa giá trị pixel?
- Baseline (ví dụ Logistic Regression trên pixel thô) đạt bao nhiêu? MLP cải thiện ra sao?
- Ma trận nhầm lẫn cho thấy những cặp chữ số nào hay bị nhầm?

- Đường cong học cho thấy mô hình bắt đầu quá khớp ở đâu?
- So sánh chi phí và độ chính xác giữa mô hình đơn giản và mạng nơ-ron.

Đề tài 14 — Phân loại ảnh thời trang bằng mạng nơ-ron (Fashion-MNIST)

- Vì sao bài toán này khó hơn phân loại chữ số viết tay?
- Nhóm dùng MLP, CNN hay đặc trưng từ mô hình tiền huấn luyện? Khác biệt ra sao?
- Tăng cường dữ liệu (augmentation) chỉ được áp dụng cho tập nào? Vì sao?
- Những lớp quần áo nào hay bị nhầm với nhau (theo ma trận nhầm lẫn)?
- Khi nào mạng nơ-ron là "quá mức cần thiết" cho dữ liệu này?

Đề tài 15 — Phân loại loài hoa Iris / chim cánh cụt Palmer và trực quan hóa ranh giới quyết định

- Đây là phân lớp nhiều lớp; các loài có tách biệt rõ trên biểu đồ phân tán không?
- Nhóm trực quan hóa ranh giới quyết định bằng cách nào (chọn 2 đặc trưng hoặc chiếu PCA)?
- Các cột thiếu (ở bộ Penguins) được xử lý thế nào?
- Ranh giới quyết định của mô hình tuyến tính và mô hình phi tuyến khác nhau ra sao?
- Vì sao đây là bài toán "nhập môn" tốt nhưng vẫn phải làm đủ quy trình?